

[论文解析]Scaffold-GS：视图自适应渲染的重建

Scaffold-GS：视图自适应渲染的重建

一种隐式和显式表达的结合方法，三个主要贡献点：1. 三维高斯表示场景，锚点和voxel结合去掉冗余高斯，更注重场景的结构表示；2. 用MLP来训练高斯的增删策略替换了原版的高斯增删策略；

论文地址：[2312.00109] Scaffold-GS: Structured 3D Gaussians for View-Adaptive Rendering (arxiv.org)

源码地址：GitHub - city-super/Scaffold-GS: [CVPR 2024 Highlight] Scaffold-GS: Structured 3D Gaussians for View-Adaptive Rendering

项目地址：Scaffold-GS: Structured 3D Gaussians for View-Adaptive Rendering (city-super.github.io)

Scaffold-GS

Scaffold-GS：视图自适应渲染的重建

论文解读（来自ChatGpt）

研究背景与动机

研究贡献

方法

实验设计与评估

结论与未来工作

代码及论文具体细节

如何进行锚点初始化

MLP如何进行初始化

训练过程

anchor的调整

参考文献

论文解读（来自ChatGpt ）

研究背景与动机

在计算机视觉 领域，尤其是3D场景渲染方面，实现高质量的视觉效果与实时渲染 性能 的平衡一直是一个挑战。尽管最近的方法如3D Gaussian Splatting在渲染质量和速度上取得了显著进展，但它们在处理大规模场景和复杂光照条件下的冗余性和鲁棒性不足。

研究贡献

本研究的核心贡献在于提出了Scaffold-GS，这是一种基于锚点的分层3D高斯表示方法，能够动态适应不同的观察角度和距离，显著提升了渲染的鲁棒性；包括：

1. 结构化3D场景表示：通过从结构从运动（SfM）初始化的稀疏锚点网格，引导局部3D高斯的分布，形成层次化和区域感知的场景表示。
1. 从论文的图6中可以看到点云的结构特征比较明显，聚类算法可以将物体点云聚集为同一类；
2. 视图自适应属性预测：在视锥体内，基于锚点特征和视图依赖信息实时预测神经高斯的属性，如不透明度和颜色，以适应多样化的视图方向和距离。
3. 锚点生长与修剪策略：开发了一种基于神经高斯重要性的锚点生长和修剪机制，以提高场景覆盖的可靠性。
1. 这一点其实是适配他们自己提出的anchor特性，感觉可以在destiny和prune的条件部分做些优化和修改(可惜暂时没有好的想法)

方法

Scaffold-GS采用了一种新颖的方法，包括：

- 锚点初始化：利用SfM点云构建稀疏锚点网格，为场景提供一个粗略的几何框架。原版是用SfM的点作为高斯初始化点，这里将点云体素化，每一个voxel作为一个anchor，并规定了voxel尺寸，为每个anchor构造了相应的feature bank；
- 神经高斯衍生：从每个锚点生成一组神经高斯，其属性通过小型多层感知器（MLP）基于视图方向和距离动态预测。
- 属性预过滤策略：为了提高光栅化效率，引入了基于不透明度阈值的预过滤步骤，以减少计算负载。

实验设计与评估

研究者在多个公共数据集上对Scaffold-GS进行了全面评估，包括：

- **数据集**：涵盖了从Mip-NeRF360到Tanks&Temples，再到DeepBlending和Blender合成数据集的多样化场景。
- **评估指标**：采用了峰值信噪比（PSNR）、结构相似性（SSIM）、感知损失（LPIPS）等指标，以及存储大小和帧率（FPS）来衡量模型的性能和效率
- **细节设置**：设置每个voxel为10个3D高斯，MLP设置为2层，RELU激活函数，隐含层为32维度，SSIM和vol的损失权重为0.2和0.001；
- **结果分析**：Scaffold-GS在保持与原始3D-GS相似的渲染速度的同时，显著减少了存储需求，并在具有挑战性的场景中展现出更好的视觉质量和鲁棒性。

结论与未来工作

Scaffold-GS通过其结构化的3D高斯和视图自适应属性预测，为3D场景渲染领域提供了一种高效的解决方案。论文还讨论了该方法的局限性，并对未来可了展望，包括在更大规模场景中的应用和对无纹理区域的处理策略。

代码及论文具体细节

如何进行锚点初始化

1. 从SfM点云进行voxel初始化，生成了 $V = \{\frac{P}{\epsilon}\}$ · ϵ 个anchor锚点，anchor的生成就是简单的voxel采样

```

1 def create_from_pcd(self, pcd : BasicPointCloud, spatial_lr_scale : float):
2     self.spatial_lr_scale = spatial_lr_scale
3     points = pcd.points[:, :self.ratio]
4
5     if self.voxel_size <= 0: # 保留了原版的点云初始化
6         init_points = torch.tensor(points).float().cuda()
7         init_dist = distCUDA2(init_points).float().cuda()
8         median_dist, _ = torch.kthvalue(init_dist, int(init_dist.shape[0]*0.5))
9         self.voxel_size = median_dist.item()
10        del init_dist
11        del init_points
12        torch.cuda.empty_cache()
13
14        print(f'Initial voxel_size: {self.voxel_size}')
15
16
17        points = self.voxelize_sample(points, voxel_size=self.voxel_size) # 下采样
18        fused_point_cloud = torch.tensor(np.asarray(points)).float().cuda()
19        offsets = torch.zeros((fused_point_cloud.shape[0], self.n_offsets, 3)).float().cuda()
20        # anchor的feature初始化
21        anchors_feat = torch.zeros((fused_point_cloud.shape[0], self.feats_dim)).float().cuda()
22
23        print("Number of points at initialisation : ", fused_point_cloud.shape[0])
24
25        dist2 = torch.clamp_min(distCUDA2(fused_point_cloud).float().cuda(), 0.0000001)
26        scales = torch.log(torch.sqrt(dist2))[...,None].repeat(1, 6)
27
28        rots = torch.zeros((fused_point_cloud.shape[0], 4), device="cuda")
29        rots[:, 0] = 1
30
31        opacities = inverse_sigmoid(0.1 * torch.ones((fused_point_cloud.shape[0], 1), dtype=torch.float, device="cuda"))
32        # 以下变量为优化器需要进行优化的参数
33        self._anchor = nn.Parameter(fused_point_cloud.requires_grad_(True))
34        self._offset = nn.Parameter(offsets.requires_grad_(True))
35        self._anchor_feat = nn.Parameter(anchors_feat.requires_grad_(True))
36        self._scaling = nn.Parameter(scales.requires_grad_(True))
37        self._rotation = nn.Parameter(rots.requires_grad_(False))
38        self._opacity = nn.Parameter(opacities.requires_grad_(False))
39        self.max_radii2D = torch.zeros((self.get_anchor.shape[0]), device="cuda")

```

1. 需要优化的参数有下面几个：

- `self._anchor` 的xyz是需要进行优化的参数，也就是anchor是需要不断调整的；
- `self._offset` 是每个anchor衍生出的Gaussian的位置，代码中设置为10，每个anchor生成10个Gaussian，这里的offset相当于以anchor为原点的编码中的表达就是方向向量；
- `self._anchor_feat` 就是下面要讲的每个anchor的特征，这个特征量应该是作为MLP的输入层；
- `self._scaling` 初始化是一个6维参数，前3维是offset的缩放系数，后3维表示neural-gs的cov的初值，对应论文公式8中的 l_v

```

1 # render里面的 generate_neural_gaussians函数
2 # post-process cov
3 scaling = scaling_repeat[:,3:] * torch.sigmoid(scale_rot[:,3:]) # * (1+torch.sigmoid(repeat_dist))
4 rot = pc.rotation_activation(scale_rot[:,3:7])
5
6 # post-process offsets to get centers for gaussians
7 offsets = offsets * scaling_repeat[:,3:]
8 xyz = repeat_anchor + offsets

```

- `self._rotation` , `self._opacity` 初始化，后续在 `adjust_anchor()` 进行更新调用

MLP如何进行初始化

1. 每个锚点配置了4个小型MLP用来计算三维高斯需要优化的属性，也就是用MLP对属性进行预测，而不是原版的优化策略；**MLP的初始化细节和结构 GaussianModel 里面的 `setup_functions` 和 `__init__` 函数。**
2. 第一个MLP是feature bank的权重，是每个anchor都有的32维特征(个人感觉32就是为了方便下采样和小型网络)，通过下采样扩展出另外两种特征；这个featbank设计的，如下图
3. 剩余3个MLP是对应了三维高斯的属性，如下图所示；N是anchor个数，由于颜色是通过MLP预测，所以没有SH系数；MLP的设计在论文的第7节。

训练过程

1. 训练初始化：模型初始化，学习率设置

```

1 l = [
2     # 高斯参数
3     {'params': [self._anchor], 'lr': training_args.position_lr_init * self.spatial_lr_scale, "name": "anchor"},
4     {'params': [self._offset], 'lr': training_args.offset_lr_init * self.spatial_lr_scale, "name": "offset"},
5     {'params': [self._anchor_feat], 'lr': training_args.feature_lr, "name": "anchor_feat"},
6     {'params': [self._opacity], 'lr': training_args.opacity_lr, "name": "opacity"},
7     {'params': [self._scaling], 'lr': training_args.scaling_lr, "name": "scaling"},
8     {'params': [self._rotation], 'lr': training_args.rotation_lr, "name": "rotation"},
9     # MLP参数
10    {'params': self.mlp_opacity.parameters(), 'lr': training_args.mlp_opacity_lr_init, "name": "mlp_opacity"},
11    {'params': self.mlp_feature_bank.parameters(), 'lr': training_args.mlp_featurebank_lr_init, "name": "mlp_featurebank"},
12    {'params': self.mlp_cov.parameters(), 'lr': training_args.mlp_cov_lr_init, "name": "mlp_cov"},
13    {'params': self.mlp_color.parameters(), 'lr': training_args.mlp_color_lr_init, "name": "mlp_color"},
14    {'params': self.embedding_appearance.parameters(), 'lr': training_args.appearance_lr_init, "name": "embedding_appearance"},
15 ]
16 # 优化器设置
17 self.optimizer = torch.optim.Adam(l, lr=0.0, eps=1e-15)
18 *** 后面为每个参数设置了学习率更新方法，和原版一致**

```

2. 每次训练随机选择一个相机进行训练，避免过拟合

```

1 # Pick a random Camera
2 if not viewpoint_stack:
3     viewpoint_stack = scene.getTrainCameras().copy()
4 viewpoint_cam = viewpoint_stack.pop(randint(0, len(viewpoint_stack)-1))

```

3. 过滤视椎体之外的anchor, 并生成neural-gs

```

1 # train函数
2 voxel_visible_mask = prefilter_voxel(viewpoint_cam, gaussians, pipe, background)
3 # 生成Gaussian, 这段代码在render函数里面
4 if is_training:
5     xyz, color, opacity, scaling, rot, neural_opacity, mask = generate_neural_gaussians(viewpoint_camera, pc, visible_ma
6 else:
7     xyz, color, opacity, scaling, rot = generate_neural_gaussians(viewpoint_camera, pc, visible_mask, is_training=is_tra

```

4. 计算anchor到相机中心的距离和方向, 对应论文公式5

```

1 ## get view properties for anchor
2 ob_view = anchor - viewpoint_camera.camera_center
3 # dist
4 ob_dist = ob_view.norm(dim=1, keepdim=True)
5 # view
6 ob_view = ob_view / ob_dist

```

5. 高斯参数的预测, MLP的调用

```

1 cat_local_view = torch.cat([feat, ob_view, ob_dist], dim=1) # [N, c+3+1]
2 cat_local_view_wodist = torch.cat([feat, ob_view], dim=1) # [N, c+3]
3 if pc.appearance_dim > 0:
4     camera_indicies = torch.ones_like(cat_local_view[:,0], dtype=torch.long, device=ob_dist.device) * viewpoint_camera.u
5     # camera_indicies = torch.ones_like(cat_local_view[:,0], dtype=torch.long, device=ob_dist.device) * 10
6     appearance = pc.get_appearance(camera_indicies)
7
8 # get offset's opacity
9 if pc.add_opacity_dist: # 该flag为false
10     neural_opacity = pc.get_opacity_mlp(cat_local_view) # [N, k]
11 else: # 调用此分支, 用anchor的feat和方向预测高斯的opacity, 输出维度[N, k]
12     neural_opacity = pc.get_opacity_mlp(cat_local_view_wodist)
13
14 # get offset's color, color的预测
15 if pc.appearance_dim > 0:
16     if pc.add_color_dist:
17         color = pc.get_color_mlp(torch.cat([cat_local_view, appearance], dim=1))
18     else:
19         color = pc.get_color_mlp(torch.cat([cat_local_view_wodist, appearance], dim=1))
20 else:
21     if pc.add_color_dist:
22         color = pc.get_color_mlp(cat_local_view)
23     else:
24         color = pc.get_color_mlp(cat_local_view_wodist)
25 # 颜色矩阵改为[N*k, 3], 对应到每个三维高斯
26 color = color.reshape([anchor.shape[0]*pc.n_offsets, 3]) # [mask]
27
28 # get offset's cov协方差预测
29 if pc.add_cov_dist:
30     scale_rot = pc.get_cov_mlp(cat_local_view)
31 else: # 使用该分支, 输入35维参数, 输出为70维
32     scale_rot = pc.get_cov_mlp(cat_local_view_wodist)
33 scale_rot = scale_rot.reshape([anchor.shape[0]*pc.n_offsets, 7]) # [mask]
34

```

```

35 # post-process cov, 协方差分解为旋转和scaling
36 scaling = scaling_repeat[:,3:] * torch.sigmoid(scale_rot[:,3:]) # * (1+torch.sigmoid(repeat_dist))
37 rot = pc.rotation_activation(scale_rot[:,3:7])
38
39 # post-process offsets to get centers for gaussians
40 # 将scaling作用到生成的offset赋给每一个高斯生成xyz
41 offsets = offsets * scaling_repeat[:,3:]
   xyz = repeat_anchor + offsets

```

6. 学习率更新, 主要的更新函数为原版代码中的 `get_expon_lr_func`, 具体公式参考之前的3DGS文章解析;

anchor的调整

统计模型信息 `training_stat` 函数

- 更新了anchor调整中用到的不透明度累积值 `self.opacity_accum`, 锚点观测数量 `self.anchor_demon`, offset的梯度累积值 `self.offset_gradie` 观测次数 `self.offset_denom` 四个变量

锚点调整函数 `adjust_anchor()`

- `self.offset_gradient_accum` 是所有视角下可见高斯的梯度累积, 在这里对所有视角下的高斯统一再次进行归一化; 根据每个offset数量过滤生成offsetmask, 计数超过40的考虑增加anchor;

```

1 # adding anchors
2 grads = self.offset_gradient_accum / self.offset_denom # [N*k, 1]
3 grads[grads.isnan()] = 0.0
4 grads_norm = torch.norm(grads, dim=-1)
5 # threshold = 40
6 offset_mask = (self.offset_denom > check_interval*success_threshold*0.5).squeeze(dim=1)
7
8 self.anchor_growing(grads_norm, grad_threshold, offset_mask)

```

- `anchor_growing()`, 也就是锚点的分割;

- 通过阶数 $i \in (0, 1, 2)$ 来控制梯度阈值 (i 对应论文公式中的 m), `random pick` 的比例, `voxel` 的尺寸, 0阶不进行anchor的增加; (这里控制: 件, 可以考虑优化)
- 根据 `voxel` (几倍的 `voxel_size`) 确定Gaussian和anchor的grid坐标, 并对高斯的grid坐标去重; ($\text{voxel_size} \cdot (\frac{\text{update_init_factor}}{\text{update_hierachy_factor}})$)
- 从高斯的grid坐标中去掉anchor坐标 (代码采用分块并行, 否则可能会显存爆炸), 生成新的anchor;
- 新anchor的初始化和模型初始化的设置一致, 参考 `create_from_pcd()`

```

1 # update threshold, i是当前阶数, update_hierachy_factor=0.0002
2 cur_threshold = threshold*((self.update_hierachy_factor//2)**i)
3 # mask from grad threshold
4 candidate_mask = (grads >= cur_threshold)
5 candidate_mask = torch.logical_and(candidate_mask, offset_mask)
6
7 # random pick
8 rand_mask = torch.rand_like(candidate_mask.float()) > (0.5**(i+1))
9 rand_mask = rand_mask.cuda()
10 candidate_mask = torch.logical_and(candidate_mask, rand_mask)

```

- 更新新增anchor下面的高斯梯度, 全部赋值为0
- anchor删减: a)透明度小于阈值; b)anchor个数大于阈值; 两者取交集, 即为anchor的 `prune_mask`
- 根据 `prune_mask` 再次更新anchor扩增的offset梯度及个数;
- 根据 `prune_mask` 重新计算 `opacity_accum` 和 `anchor_demon` ;

参考文献

1. 论文解读: <https://zhuanlan.zhihu.com/p/682414775>
2. 代码链接: <https://github.com/city-super/Scaffold-GS>
3. 源码解读: https://blog.csdn.net/qq_41623632/article/details/137602801