

## 12 生成扩散模型漫谈（七）：最优扩散方差估计（上）

Aug By 苏剑林 | 2022-08-12 | 74569位读者 引用

对于生成扩散模型来说，一个很关键的问题是生成过程的方差应该怎么选择，因为不同的方差会明显影响生成效果。

在《生成扩散模型漫谈（二）：DDPM = 自回归式VAE》我们提到，DDPM分别假设数据服从两种特殊分布推出了两个可用的结果；《生成扩散模型漫谈（四）：DDIM = 高观点DDPM》中的DDIM则调整了生成过程，将方差变为超参数，甚至允许零方差生成，但方差为0的DDIM的生成效果普遍差于方差非0的DDPM；而《生成扩散模型漫谈（五）：一般框架之SDE篇》显示前、反向SDE的方差应该是一致的，但这原则上在 $\Delta t \rightarrow 0$ 时才成立；《Improved Denoising Diffusion Probabilistic Models》则提出将它视为可训练参数来学习，但会增加训练难度。

所以，生成过程的方差究竟该怎么设置呢？今年的两篇论文《Analytic-DPM: an Analytic Estimate of the Optimal Reverse Variance in Diffusion Probabilistic Models》和《Estimating the Optimal Covariance with Imperfect Mean in Diffusion Probabilistic Models》算是给这个问题提供了比较完美的答案。接下来我们一起欣赏一下它们的结果。

### 不确定性 #

事实上，这两篇论文出自同一团队，作者也基本相同。第一篇论文（简称Analytic-DPM）下面简称在DDIM的基础上，推导了无条件方差的一个解析解；第二篇论文（简称Extended-Analytic-DPM）则弱化了第一篇论文的假设，并提出了有条件方差的优化方法。本文首先介绍第一篇论文的结果。

在《生成扩散模型漫谈（四）：DDIM = 高观点DDPM》中，我们推导了对于给定的 $p(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \bar{\alpha}_t\mathbf{x}_0, \bar{\beta}_t^2\mathbf{I})$ ，对应的 $p(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 的一般解为

$$p(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}\left(\mathbf{x}_{t-1}; \frac{\sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t} \mathbf{x}_t + \gamma_t \mathbf{x}_0, \sigma_t^2 \mathbf{I}\right) \quad (1)$$

其中  $\gamma_t = \bar{\alpha}_{t-1} - \frac{\bar{\alpha}_t \sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t}$ ， $\sigma_t$  就是可调的标准差参数。在 DDIM 中，接下来的处理流程是：用  $\bar{\boldsymbol{\mu}}(\mathbf{x}_t)$  来估计  $\mathbf{x}_0$ ，然后认为

$$p(\mathbf{x}_{t-1}|\mathbf{x}_t) \approx p(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0 = \bar{\boldsymbol{\mu}}(\mathbf{x}_t)) \quad (2)$$

然而，从贝叶斯的角度来看，这个处理是非常不妥的，因为从  $\mathbf{x}_t$  预测  $\mathbf{x}_0$  不可能完全准确，它带有一定的不确定性，因此我们应该用概率分布而非确定性的函数来描述它。事实上，严格地有

$$p(\mathbf{x}_{t-1}|\mathbf{x}_t) = \int p(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) p(\mathbf{x}_0|\mathbf{x}_t) d\mathbf{x}_0 \quad (3)$$

精确的  $p(\mathbf{x}_0|\mathbf{x}_t)$  通常是没法获得的，但这里只要一个粗糙的近似，因此我们用正态分布  $\mathcal{N}(\mathbf{x}_0; \bar{\boldsymbol{\mu}}(\mathbf{x}_t), \bar{\sigma}_t^2 \mathbf{I})$  去逼近它（如何逼近我们稍后再讨论）。有了这个近似分布后，我们可以写出

$$\begin{aligned} \mathbf{x}_{t-1} &= \frac{\sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t} \mathbf{x}_t + \gamma_t \mathbf{x}_0 + \sigma_t \boldsymbol{\epsilon}_1 \\ &\approx \frac{\sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t} \mathbf{x}_t + \gamma_t (\bar{\boldsymbol{\mu}}(\mathbf{x}_t) + \bar{\sigma}_t \boldsymbol{\epsilon}_2) + \sigma_t \boldsymbol{\epsilon}_1 \\ &= \left( \frac{\sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t} \mathbf{x}_t + \gamma_t \bar{\boldsymbol{\mu}}(\mathbf{x}_t) \right) + \underbrace{(\sigma_t \boldsymbol{\epsilon}_1 + \gamma_t \bar{\sigma}_t \boldsymbol{\epsilon}_2)}_{\sim \sqrt{\sigma_t^2 + \gamma_t^2 \bar{\sigma}_t^2} \boldsymbol{\epsilon}} \end{aligned} \quad (4)$$

其中  $\boldsymbol{\epsilon}_1, \boldsymbol{\epsilon}_2, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。可以看到， $p(\mathbf{x}_{t-1}|\mathbf{x}_t)$  更加接近均值为

$\frac{\sqrt{\bar{\beta}_{t-1}^2 - \sigma_t^2}}{\bar{\beta}_t} \mathbf{x}_t + \gamma_t \bar{\boldsymbol{\mu}}(\mathbf{x}_t)$ 、协方差为  $(\sigma_t^2 + \gamma_t^2 \bar{\sigma}_t^2) \mathbf{I}$  的正态分布，其中均值跟以往的结果

是一致的，不同的是方差多出了 $\gamma_t^2 \bar{\sigma}_t^2$ 这一项，因此即便 $\sigma_t = 0$ ，对应的方差也不为0。多出来的这一项，就是第一篇论文所提的最优方差的修正项。

## 均值优化 #

现在我们来讨论如何用 $\mathcal{N}(\mathbf{x}_0; \bar{\boldsymbol{\mu}}(\mathbf{x}_t), \bar{\sigma}_t^2 \mathbf{I})$ 去逼近真实的 $p(\mathbf{x}_0|\mathbf{x}_t)$ ，说白了就是求出 $p(\mathbf{x}_0|\mathbf{x}_t)$ 的均值和协方差。

对于均值 $\bar{\boldsymbol{\mu}}(\mathbf{x}_t)$ 来说，它依赖于 $\mathbf{x}_t$ ，所以需要有一个模型来拟合它，而训练模型就需要损失函数。利用

$$\mathbb{E}_{\mathbf{x}}[\mathbf{x}] = \underset{\boldsymbol{\mu}}{\operatorname{argmin}} \mathbb{E}_{\mathbf{x}} [\|\mathbf{x} - \boldsymbol{\mu}\|^2] \quad (5)$$

我们得到

$$\begin{aligned} \bar{\boldsymbol{\mu}}(\mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} [\mathbf{x}_0] \\ &= \underset{\boldsymbol{\mu}}{\operatorname{argmin}} \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} [\|\mathbf{x}_0 - \boldsymbol{\mu}\|^2] \\ &= \underset{\boldsymbol{\mu}(\mathbf{x}_t)}{\operatorname{argmin}} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} [\|\mathbf{x}_0 - \boldsymbol{\mu}(\mathbf{x}_t)\|^2] \\ &= \underset{\boldsymbol{\mu}(\mathbf{x}_t)}{\operatorname{argmin}} \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t|\mathbf{x}_0)} [\|\mathbf{x}_0 - \boldsymbol{\mu}(\mathbf{x}_t)\|^2] \end{aligned} \quad (6)$$

这就是训练 $\bar{\boldsymbol{\mu}}(\mathbf{x}_t)$ 所用的损失函数。如果像之前一样引入参数化

$$\bar{\boldsymbol{\mu}}(\mathbf{x}_t) = \frac{1}{\bar{\alpha}_t} (\mathbf{x}_t - \bar{\beta}_t \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t)) \quad (7)$$

就可以得到DDPM训练所用的损失函数形式 $\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\theta}(\bar{\alpha}_t \mathbf{x}_0 + \bar{\beta}_t \boldsymbol{\epsilon}, t)\|^2$ 了。关于均值优化的结果是跟以往一致的，没有什么改动。

## 方差估计1 #

类似地，根据定义，协方差矩阵应该是

$$\begin{aligned}\Sigma(\mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ (\mathbf{x}_0 - \bar{\boldsymbol{\mu}}(\mathbf{x}_t)) (\mathbf{x}_0 - \bar{\boldsymbol{\mu}}(\mathbf{x}_t))^\top \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ ((\mathbf{x}_0 - \boldsymbol{\mu}) - (\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu})) ((\mathbf{x}_0 - \boldsymbol{\mu}) - (\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}))^\top \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ (\mathbf{x}_0 - \boldsymbol{\mu}_0)(\mathbf{x}_0 - \boldsymbol{\mu}_0)^\top \right] - (\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0)(\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0)^\top\end{aligned}$$

其中 $\boldsymbol{\mu}_0$ 可以是任意常向量，这对应于协方差的平移不变性。

上式估计的是完整的协方差矩阵，但并不是我们想要的，因为目前我们是想要用 $\mathcal{N}(\mathbf{x}_0; \bar{\boldsymbol{\mu}}(\mathbf{x}_t), \bar{\sigma}_t^2 \mathbf{I})$ 去逼近 $p(\mathbf{x}_0|\mathbf{x}_t)$ ，其中设计的协方差矩阵为 $\bar{\sigma}_t^2 \mathbf{I}$ ，它有两个特点：

1、跟 $\mathbf{x}_t$ 无关：为了消除对 $\mathbf{x}_t$ 的依赖，我们对全体 $\mathbf{x}_t$ 求平均，即

$$\Sigma_t = \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} [\Sigma(\mathbf{x}_t)];$$

2、单位阵的倍数：这意味着我们只用考虑对角线部分，并且对对角线元素取平均，即

$$\bar{\sigma}_t^2 = \text{Tr}(\Sigma_t)/d, \text{ 其中 } d = \dim(\mathbf{x}).$$

于是我们有

$$\begin{aligned}\bar{\sigma}_t^2 &= \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ \frac{\|\mathbf{x}_0 - \boldsymbol{\mu}_0\|^2}{d} \right] - \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} \left[ \frac{\|\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0\|^2}{d} \right] \\ &= \frac{1}{d} \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t|\mathbf{x}_0)} [\|\mathbf{x}_0 - \boldsymbol{\mu}_0\|^2] - \frac{1}{d} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} [\|\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0\|^2] \quad (9) \\ &= \frac{1}{d} \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} [\|\mathbf{x}_0 - \boldsymbol{\mu}_0\|^2] - \frac{1}{d} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} [\|\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0\|^2]\end{aligned}$$

这是笔者给出的关于 $\bar{\sigma}_t^2$ 的一个解析形式，在 $\bar{\boldsymbol{\mu}}(\mathbf{x}_t)$ 完成训练的情况下，可以通过采样一批 $\mathbf{x}_0$ 和 $\mathbf{x}_t$ 来近似计算上式。

特别地，如果取 $\boldsymbol{\mu}_0 = \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} [\mathbf{x}_0]$ ，那么刚好可以写成

$$\bar{\sigma}_t^2 = \text{Var}[\mathbf{x}_0] - \frac{1}{d} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} [\|\bar{\boldsymbol{\mu}}(\mathbf{x}_t) - \boldsymbol{\mu}_0\|^2] \quad (10)$$

这里的 $\text{Var}[\mathbf{x}_0]$ 是全体训练数据 $\mathbf{x}_0$ 的像素级方差。如果 $\mathbf{x}_0$ 的每个像素值都在 $[a, b]$ 区间

内，那么它的方差显然不会超过 $\left(\frac{b-a}{2}\right)^2$ ，从而有不等式

$$\bar{\sigma}_t^2 \leq \mathbb{V}ar[\mathbf{x}_0] \leq \left(\frac{b-a}{2}\right)^2 \quad (11)$$

## 方差估计2 #

刚才的解是笔者给出的、认为比较直观的一个解，Analytic-DPM原论文则给出了一个略有不同的解，但笔者认为相对来说没那么直观。通过代入式(7)，我们可以得到：

$$\begin{aligned} \Sigma(\mathbf{x}_t) &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ (\mathbf{x}_0 - \bar{\boldsymbol{\mu}}(\mathbf{x}_t)) (\mathbf{x}_0 - \bar{\boldsymbol{\mu}}(\mathbf{x}_t))^\top \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ \left( \left( \mathbf{x}_0 - \frac{\mathbf{x}_t}{\bar{\alpha}_t} \right) + \frac{\bar{\beta}_t}{\bar{\alpha}_t} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right) \left( \left( \mathbf{x}_0 - \frac{\mathbf{x}_t}{\bar{\alpha}_t} \right) + \frac{\bar{\beta}_t}{\bar{\alpha}_t} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \right)^\top \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ \left( \mathbf{x}_0 - \frac{\mathbf{x}_t}{\bar{\alpha}_t} \right) \left( \mathbf{x}_0 - \frac{\mathbf{x}_t}{\bar{\alpha}_t} \right)^\top \right] - \frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)^\top \\ &= \frac{1}{\bar{\alpha}_t^2} \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0) (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0)^\top \right] - \frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t) \boldsymbol{\epsilon}_\theta(\mathbf{x}_t, t)^\top \end{aligned}$$

此时如果两端对 $\mathbf{x}_t \sim p(\mathbf{x}_t)$ 求平均，我们有

$$\begin{aligned} &\mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t)} \mathbb{E}_{\mathbf{x}_0 \sim p(\mathbf{x}_0|\mathbf{x}_t)} \left[ (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0) (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0)^\top \right] \\ &= \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t|\mathbf{x}_0)} \left[ (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0) (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0)^\top \right] \end{aligned} \quad (13)$$

别忘了 $p(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \bar{\alpha}_t \mathbf{x}_0, \bar{\beta}_t^2 \mathbf{I})$ ，所以 $\bar{\alpha}_t \mathbf{x}_0$ 实际上就是 $p(\mathbf{x}_t|\mathbf{x}_0)$ 的均值，那么 $\mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t|\mathbf{x}_0)} \left[ (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0) (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0)^\top \right]$ 实际上是在求 $p(\mathbf{x}_t|\mathbf{x}_0)$ 的均值的协方差矩阵，结果显然就是 $\bar{\beta}_t^2 \mathbf{I}$ ，所以

$$\mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} \mathbb{E}_{\mathbf{x}_t \sim p(\mathbf{x}_t|\mathbf{x}_0)} \left[ (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0) (\mathbf{x}_t - \bar{\alpha}_t \mathbf{x}_0)^\top \right] = \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0)} \left[ \bar{\beta}_t^2 \mathbf{I} \right] = \bar{\beta}_t^2 \mathbf{I} \quad (1)$$

那么

$$\Sigma_t = \mathbb{E}_{\boldsymbol{x}_t \sim p(\boldsymbol{x}_t)} [\Sigma(\boldsymbol{x}_t)] = \frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \left( \boldsymbol{I} - \mathbb{E}_{\boldsymbol{x}_t \sim p(\boldsymbol{x}_t)} \left[ \boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t) \boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)^\top \right] \right) \tag{15}$$

两边取迹然后除以 $d$ ，得到

$$\bar{\sigma}_t^2 = \frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \left( 1 - \frac{1}{d} \mathbb{E}_{\boldsymbol{x}_t \sim p(\boldsymbol{x}_t)} [\|\boldsymbol{\epsilon}_\theta(\boldsymbol{x}_t, t)\|^2] \right) \leq \frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \tag{16}$$

这就得到了另一个估计和上界，这就是Analytic-DPM的原始结果。

实验结果 #

原论文的实验结果显示，Analytic-DPM所做的方差修正，主要在生成扩散步数较少时会有比较明显的提升，所以它对扩散模型的加速比较有意义：


Model \ # timesteps $K$	10	25	50	100	200	400	1000
CIFAR10 (LS)							
DDPM, $\sigma_n^2 = \tilde{\beta}_n$	44.45	21.83	15.21	10.94	8.23	6.43	5.11
DDPM, $\sigma_n^2 = \beta_n$	233.41	125.05	66.28	31.36	12.96	4.86	<sup>†</sup> <b>3.04</b>
Analytic-DDPM	<b>34.26</b>	<b>11.60</b>	<b>7.25</b>	<b>5.40</b>	<b>4.01</b>	<b>3.62</b>	4.03
DDIM	21.31	10.70	7.74	6.08	5.07	4.61	4.13
Analytic-DDIM	<b>14.00</b>	<b>5.81</b>	<b>4.04</b>	<b>3.55</b>	<b>3.39</b>	<b>3.50</b>	<b>3.74</b>
CIFAR10 (CS)							
DDPM, $\sigma_n^2 = \tilde{\beta}_n$	34.76	16.18	11.11	8.38	6.66	5.65	4.92
DDPM, $\sigma_n^2 = \beta_n$	205.31	84.71	37.35	14.81	5.74	<b>3.40</b>	<b>3.34</b>
Analytic-DDPM	<b>22.94</b>	<b>8.50</b>	<b>5.50</b>	<b>4.45</b>	<b>4.04</b>	3.96	4.31
DDIM	34.34	16.68	10.48	7.94	6.69	5.78	4.89
Analytic-DDIM	<b>26.43</b>	<b>9.96</b>	<b>6.02</b>	<b>4.88</b>	<b>4.92</b>	<b>5.00</b>	<b>4.66</b>
CelebA 64x64							
DDPM, $\sigma_n^2 = \tilde{\beta}_n$	36.69	24.46	18.96	14.31	10.48	8.09	5.95
DDPM, $\sigma_n^2 = \beta_n$	294.79	115.69	53.39	25.65	9.72	<b>3.95</b>	<b>3.16</b>
Analytic-DDPM	<b>28.99</b>	<b>16.01</b>	<b>11.23</b>	<b>8.08</b>	<b>6.51</b>	5.87	5.21
DDIM	20.54	13.45	9.33	6.60	4.96	4.15	3.40
Analytic-DDIM	<b>15.62</b>	<b>9.22</b>	<b>6.13</b>	<b>4.29</b>	<b>3.46</b>	<b>3.38</b>	<b>3.13</b>
Analytic-DPM主要在扩散步数较少时会有比较明显的效果提升							



笔者也在之前自己实现的代码上尝试了Analytic-DDPM的修正，参考代码为：

Github: <https://github.com/bojone/Keras-DDPM/blob/main/adpm.py>

当扩散步数为10时，DDPM与Analytic-DDPM的效果对比如下图：



DDPM在扩散步数为10时的生成结果



Analytic-DDPM在扩散步数为10时的生成结果

可以看到，在扩散步数较小时，DDPM的生成效果比较光滑，有点“重度磨皮”的感觉，相比之下Analytic-DDPM的结果显得更真实一些，但是也带来了额外的噪点。从评价指标来说，Analytic-DDPM要更好一些。

## 吹毛求疵 #

至此，我们已经完成了Analytic-DPM的介绍，推导过程略带有一些技巧性，但不算太复杂，至少思路还是很明朗的。如果读者觉得还是很难懂，那不妨再去看看原论文在附录中用7页纸、13个引理完成的推导，想必看到之后就觉得本文的推导是多么友好了哈哈～

诚然，从首先得到这个方差的解析解来说，我为原作者们的洞察力而折服，但不得不说的是，从“事后诸葛亮”的角度来说，Analytic-DPM在推导和结果上都走了一些的“弯路”，显得“太绕”、“太巧”，从而感觉不到什么启发性。其中，一个最明显的特点是，原论文的结果都用了 $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$ 来表达，这就带来了三个问题：一来使得推导过程特别不直观，难以理解“怎么想到的”；二来要求读者额外了解得分匹配的相关结果，增加了理解难度；最后落到实践时， $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$ 又要用回 $\bar{\mu}(\mathbf{x}_t)$ 或 $\epsilon_{\theta}(\mathbf{x}_t, t)$ 来表示，多绕一道。

本文推导的出发点是，我们是在估计正态分布的参数，对于正态分布来说，矩估计与最大似然估计相同，因此直接去估算相应的均值方差即可。结果上，没必要强行在形式上去跟 $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$ 、得分匹配对齐，因为很明显Analytic-DPM的baseline模型是DDIM，DDIM本身就没有以得分匹配为出发点，增加与得分匹配的联系，于理论和实验都无益。直接跟 $\bar{\mu}(\mathbf{x}_t)$ 或 $\epsilon_{\theta}(\mathbf{x}_t, t)$ 对齐，形式上更加直观，而且更容易跟实验形式进行转换。

## 文章小结 #

本文分享了论文Analytic-DPM中的扩散模型最优方差估计结果，它给出了直接可用的最优方差估计的解析式，使得我们不需要重新训练就可以直接应用它来改进生成效果。笔者用自己的思路简化了原论文的推导，并进行了简单的实验验证。

转载到请包括本文地址：<https://spaces.ac.cn/archives/9245>

更详细的转载事宜请参考：《科学空间FAQ》



## 如果您需要引用本文，请参考：

苏剑林. (Aug. 12, 2022). 《生成扩散模型漫谈（七）：最优扩散方差估计（上）》 [Blog post]. Retrieved from <https://spaces.ac.cn/archives/9245>

```
@online{kexuefm-9245,  
  title={生成扩散模型漫谈（七）：最优扩散方差估计（上）},  
  author={苏剑林},  
  year={2022},  
  month={Aug},  
  url={\url{https://spaces.ac.cn/archives/9245}},  
}
```