

28 生成扩散模型漫谈（二十）：从ReFlow到WGAN-GP

Jun By 苏剑林 | 2023-06-28 | 23586位读者 引用

上一篇文章《生成扩散模型漫谈（十九）：作为扩散ODE的GAN》中，我们介绍了如何将GAN理解为在另一个时间维度上的扩散ODE，简而言之，GAN实际上就是将扩散模型中样本的运动转化为生成器参数的运动！然而，该文章的推导过程依赖于Wasserstein梯度流等相对复杂和独立的内容，没法很好地跟扩散系列前面的文章连接起来，技术上显得有些“断层”。

在笔者看来，《生成扩散模型漫谈（十七）：构建ODE的一般步骤（下）》所介绍的ReFlow是理解扩散ODE的最直观方案，既然可以从扩散ODE的角度理解GAN，那么必定存在一个从ReFlow理解GAN的角度。经过一番尝试，笔者成功从ReFlow推出了类似WGAN-GP的结果。

理论回顾

之所以说“ReFlow是理解扩散ODE的最直观方案”，是因为它本身非常灵活，以及非常贴近实验代码——它能够通过ODE建立任意噪声分布到目标数据分布的映射，而且训练目标非常直观，不需要什么“弯弯绕绕”就可以直接跟实验代码对应起来。

具体来说，假设 $\mathbf{x}_0 \sim p_0(\mathbf{x}_0)$ 是先验分布采样的随机噪声， $\mathbf{x}_1 \sim p_1(\mathbf{x}_1)$ 是目标分布采样的真实样本，ReFlow允许我们指定任意从 \mathbf{x}_0 到 \mathbf{x}_1 的运动轨迹。简单起见，ReFlow选择的是直线，即

$$\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1 \quad (1)$$

现在我们求出它满足的ODE：

$$\frac{d\mathbf{x}_t}{dt} = \mathbf{x}_1 - \mathbf{x}_0 \quad (2)$$

这个ODE很简单，但是却不实用，因为我们想要的是通过ODE由 \mathbf{x}_0 生成 \mathbf{x}_1 ，但上述ODE却将我们要生成的目标放在了方程里边，可谓是“因果倒置”了。为了弥补这个缺

陷，ReFlow的思路很简单：学一个 \mathbf{x}_t 的函数去逼近 $\mathbf{x}_1 - \mathbf{x}_0$ ，学完之后就用它来取代 $\mathbf{x}_1 - \mathbf{x}_0$ ，即

$$\varphi^* = \operatorname{argmin}_{\varphi} \mathbb{E}_{\mathbf{x}_0 \sim p_0(\mathbf{x}_0), \mathbf{x}_1 \sim p_1(\mathbf{x}_1)} \left[\frac{1}{2} \|\mathbf{v}_{\varphi}(\mathbf{x}_t, t) - (\mathbf{x}_1 - \mathbf{x}_0)\|^2 \right] \quad (3)$$

以及

$$\frac{d\mathbf{x}_t}{dt} = \mathbf{x}_1 - \mathbf{x}_0 \quad \Rightarrow \quad \frac{d\mathbf{x}_t}{dt} = \mathbf{v}_{\varphi^*}(\mathbf{x}_t, t) \quad (4)$$

之前我们已经证明过，在 $\mathbf{v}_{\varphi}(\mathbf{x}_t, t)$ 具有无限拟合能力的假设下，新的ODE确实能够实现从分布 $p_0(\mathbf{x}_0)$ 到分布 $p_1(\mathbf{x}_1)$ 的样本变换。

相对运动

ReFlow的重要特性之一，是它没有限制先验分布 $p_0(\mathbf{x}_0)$ 的形式，这意味着我们可以将先验分布换成任意我们想要的分布，比如，由一个生成器 $\mathbf{g}_{\theta}(\mathbf{z})$ 变换而来的分布：

$$\mathbf{x}_0 \sim p_0(\mathbf{x}_0) \quad \Leftrightarrow \quad \mathbf{x}_0 = \mathbf{g}_{\theta}(\mathbf{z}), \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (5)$$

代入式(3)训练完成后，我们就可以利用式(4)，将任意 $\mathbf{x}_0 = \mathbf{g}_{\theta}(\mathbf{z})$ 变换为真实样本 \mathbf{x}_1 了。

然而，我们并不满足于此。前面说过，GAN是将扩散模型中样本的运动转化为生成器参数的运动，这个ReFlow的框架中同样可以如此：假设生成器当前参数为 θ_{τ} ，我们期望 $\theta_{\tau} \rightarrow \theta_{\tau+1}$ 的变化能模拟式(4)前进一小步的效果

$$\theta_{\tau+1} = \operatorname{argmin}_{\theta} \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\|\mathbf{g}_{\theta}(\mathbf{z}) - \mathbf{g}_{\theta_{\tau}}(\mathbf{z}) - \epsilon \mathbf{v}_{\varphi^*}(\mathbf{g}_{\theta_{\tau}}(\mathbf{z}), 0)\|^2 \right] \quad (6)$$

要注意，式(3)和式(4)中的 t 跟参数 θ_{τ} 中的 τ 不是同一含义，前者是ODE的时间参数，后者是训练进度，所以这里用了不同记号。此外， $\mathbf{g}_{\theta_{\tau}}(\mathbf{z})$ 是作为ODE的 \mathbf{x}_0 出现的，所以往前推一小步时，得到的是 \mathbf{x}_{ϵ} ， $\mathbf{v}_{\varphi^*}(\mathbf{x}_t, t)$ 中要代入的时间 t 是0。

现在，我们有了新的 $g_{\theta_{\tau+1}}(\mathbf{z})$ ，理论上它产生的分布更加接近真实分布一些（因为往前推了一小步），接着把它当作新的 \mathbf{x}_0 代入到式(3)训练，训练完成后又可以代入到式(6)优化生成器，以此类推，就是一个类似GAN的交替训练过程。

WGAN-GP

那么，能否将这个过程定量地跟已有的GAN联系起来呢？能！还是带梯度惩罚的WGAN-GP。

首先我们来看损失函数(3)，将求期望的部分展开，结果是

$$\frac{1}{2} \|\mathbf{v}_{\varphi}(\mathbf{x}_t, t)\|^2 - \langle \mathbf{v}_{\varphi}(\mathbf{x}_t, t), \mathbf{x}_1 - \mathbf{x}_0 \rangle + \frac{1}{2} \|\mathbf{x}_1 - \mathbf{x}_0\|^2 \quad (7)$$

第三项跟参数 φ 无关，去掉也不影响结果。现在我们假设 \mathbf{v}_{φ} 有足够强的拟合能力，以至于我们不需要显式输入 t ，那么上式作为损失函数，等价于

$$\frac{1}{2} \|\mathbf{v}_{\varphi}(\mathbf{x}_t)\|^2 - \langle \mathbf{v}_{\varphi}(\mathbf{x}_t), \mathbf{x}_1 - \mathbf{x}_0 \rangle = \frac{1}{2} \|\mathbf{v}_{\varphi}(\mathbf{x}_t)\|^2 - \left\langle \mathbf{v}_{\varphi}(\mathbf{x}_t), \frac{d\mathbf{x}_t}{dt} \right\rangle \quad (8)$$

$\mathbf{v}_{\varphi}(\mathbf{x}_t)$ 是一个输入输出维度相同的向量函数，我们进一步假设它是某个标量函数 $D_{\varphi}(\mathbf{x}_t)$ 的梯度，即 $\mathbf{v}_{\varphi}(\mathbf{x}_t) = \nabla_{\mathbf{x}_t} D_{\varphi}(\mathbf{x}_t)$ ，那么上式就是

$$\frac{1}{2} \|\nabla_{\mathbf{x}_t} D_{\varphi}(\mathbf{x}_t)\|^2 - \left\langle \nabla_{\mathbf{x}_t} D_{\varphi}(\mathbf{x}_t), \frac{d\mathbf{x}_t}{dt} \right\rangle = \frac{1}{2} \|\nabla_{\mathbf{x}_t} D_{\varphi}(\mathbf{x}_t)\|^2 - \frac{dD_{\varphi}(\mathbf{x}_t)}{dt} \quad (9)$$

假设 $D_{\varphi}(\mathbf{x}_t)$ 的变化比较平稳，那么 $\frac{dD_{\varphi}(\mathbf{x}_t)}{dt}$ 应该与它在 $t=0, t=1$ 两点处的差分 $D_{\varphi}(\mathbf{x}_1) - D_{\varphi}(\mathbf{x}_0)$ 比较接近，于是上述损失函数近似于

$$\frac{1}{2} \|\nabla_{\mathbf{x}_t} D_{\varphi}(\mathbf{x}_t)\|^2 - D_{\varphi}(\mathbf{x}_1) + D_{\varphi}(\mathbf{x}_0) \quad (10)$$

熟悉GAN的读者应该会觉得眼熟，它正是带梯度惩罚的WGAN的判别器损失函数！甚至连梯度惩罚项的 \mathbf{x}_t 的构造方式(1)都一模一样（在真假样本之间线性插值）！唯一不同的是原始WGAN-GP的梯度惩罚是以1为中心，这里是以零为中心，但事实上《W

GAN-div：一个默默无闻的WGAN填坑者》、《从动力学角度看优化算法（四）：GAN的第三个阶段》等文章已经表明以零为中心的梯度惩罚通常效果更好。

所以说，在特定的参数化和假设之下，损失函数(3)其实就等价于WGAN-GP的判别器损失。至于生成器损失，在上一篇文章《生成扩散模型漫谈（十九）：作为扩散ODE的GAN》中我们已经证明了当 $\mathbf{v}_\varphi(\mathbf{x}_t) = \nabla_{\mathbf{x}_t} D_\varphi(\mathbf{x}_t)$ 时，式(6)单步优化的梯度等价于

$$\boldsymbol{\theta}_{\tau+1} = \underset{\boldsymbol{\theta}}{\operatorname{argmin}} \mathbb{E}_{\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} [-D(\mathbf{g}_\theta(\mathbf{z}))] \quad (11)$$

的梯度，而这正好也是WGAN-GP的生成器损失。

文章小结

在这篇文章中，笔者尝试从ReFlow出发推导了WGAN-GP与扩散ODE之间的联系，这个角度相对来说更加简单直观，并且避免了Wasserstein梯度流等相对复杂的概念。

转载到请包括本文地址：<https://spaces.ac.cn/archives/9668>

更详细的转载事宜请参考：《科学空间FAQ》

如果您需要引用本文，请参考：

苏剑林. (Jun. 28, 2023). 《生成扩散模型漫谈（二十）：从ReFlow到WGAN-GP》 [Blog post]. Retrieved from <https://spaces.ac.cn/archives/9668>

```
@online{kexuefm-9668,
  title={生成扩散模型漫谈（二十）：从ReFlow到WGAN-GP},
  author={苏剑林},
  year={2023},
  month={Jun},
  url={\url{https://spaces.ac.cn/archives/9668}},
}
```

