

3 生成扩散模型漫谈（五）：一般框架之SDE篇

Aug By 苏剑林 | 2022-08-03 | 185258位读者 引用

在写生成扩散模型的第一篇文章时，就有读者在评论区推荐了宋飏博士的论文《Score-Based Generative Modeling through Stochastic Differential Equations》，可以说该论文构建了一个相当一般化的生成扩散模型理论框架，将DDPM、SDE、ODE等诸多结果联系了起来。诚然，这是一篇好论文，但并不是一篇适合初学者的论文，里边直接用到了随机微分方程（SDE）、Fokker-Planck方程、得分匹配等大量结果，上手难度还是颇大的。

不过，在经过了前四篇文章的积累后，现在我们可以尝试去学习一下这篇论文了。在接下来的文章中，笔者将尝试从尽可能少的理论基础出发，尽量复现原论文中的推导结果。

随机微分

在DDPM中，扩散过程被划分为了固定的 T 步，还是用《生成扩散模型漫谈（一）：DDPM = 拆楼 + 建楼》的类比来说，就是“拆楼”和“建楼”都被事先划分为了 T 步，这个划分有着相当大的人为性。事实上，真实的“拆”、“建”过程应该是没有刻意划分的步骤的，我们可以将它们理解为一个在时间上连续的变换过程，可以用随机微分方程（Stochastic Differential Equation, SDE）来描述。

为此，我们用下述SDE描述前向过程（“拆楼”）：

$$d\mathbf{x} = \mathbf{f}_t(\mathbf{x})dt + g_t d\mathbf{w} \quad (1)$$

相信很多读者都对SDE很陌生，笔者也只是在硕士阶段刚好接触过一段时间，略懂皮毛。不过不懂不要紧，我们只需要将它看成是下述离散形式在 $\Delta t \rightarrow 0$ 时的极限：

$$\mathbf{x}_{t+\Delta t} - \mathbf{x}_t = \mathbf{f}_t(\mathbf{x}_t)\Delta t + g_t\sqrt{\Delta t}\boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}) \quad (2)$$

再直白一点，如果假设拆楼需要1天，那么拆楼就是 \mathbf{x} 从 $t = 0$ 到 $t = 1$ 的变化过程，每

一小步的变化我们可以用上述方程描述。至于时间间隔 Δt ，我们并没有做特殊限制，只是越小的 Δt 意味着是对原始SDE越好的近似，如果取 $\Delta t = 0.001$ ，那就对应于原来的 $T = 1000$ ，如果是 $\Delta t = 0.01$ 则对应于 $T = 100$ ，等等。也就是说，在连续时间的SDE视角之下，不同的 T 是SDE不同的离散化程度的体现，它们会自动地导致相似的结果，我们不需要事先指定 T ，而是根据实际情况下的精确度来取适当的 T 进行数值计算。

所以，引入SDE形式来描述扩散模型的本质好处是“将理论分析和代码实现分离开来”，我们可以借助连续性SDE的数学工具对它做分析，而实践的时候，则只需要用任意适当的离散化方案对SDE进行数值计算。

对于式(2)，读者可能比较有疑惑的是为什么右端第一项是 $\mathcal{O}(\Delta t)$ 的，而第二项是 $\mathcal{O}(\sqrt{\Delta t})$ 的？也就是说为什么随机项的阶要比确定项的阶要高？这个还真不是那么容易解释，也是SDE比较让人迷惑的地方之一。简单来说，就是 ϵ 一直服从标准正态分布，如果随机项的权重也是 $\mathcal{O}(\Delta t)$ ，那么由于标准正态分布的均值为0、协方差为 I ，临近的随机效应会相互抵消掉，要放大到 $\mathcal{O}(\sqrt{\Delta t})$ 才能在长期结果中体现出随机效应的作用。

逆向方程

用概率的语言，式(2)意味着条件概率为

$$\begin{aligned} p(\mathbf{x}_{t+\Delta t} | \mathbf{x}_t) &= \mathcal{N}(\mathbf{x}_{t+\Delta t}; \mathbf{x}_t + \mathbf{f}_t(\mathbf{x}_t)\Delta t, g_t^2 \Delta t \mathbf{I}) \\ &\propto \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}_t(\mathbf{x}_t)\Delta t\|^2}{2g_t^2 \Delta t}\right) \end{aligned} \quad (3)$$

简单起见，这里没有写出无关紧要的归一化因子。按照DDPM的思想，我们最终是想从“拆楼”的过程中学会“建楼”，即得到 $p(\mathbf{x}_t | \mathbf{x}_{t+\Delta t})$ ，为此，我们像《生成扩散模型漫谈（三）：DDPM = 贝叶斯 + 去噪》一样，用贝叶斯定理：

$$p(\mathbf{x}_t|\mathbf{x}_{t+\Delta t}) = \frac{p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t)p(\mathbf{x}_t)}{p(\mathbf{x}_{t+\Delta t})} = p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t) \exp(\log p(\mathbf{x}_t) - \log p(\mathbf{x}_{t+\Delta t})) \\ \propto \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - \mathbf{f}_t(\mathbf{x}_t)\Delta t\|^2}{2g_t^2\Delta t} + \log p(\mathbf{x}_t) - \log p(\mathbf{x}_{t+\Delta t})\right)$$

不难发现，当 Δt 足够小时，只有当 $\mathbf{x}_{t+\Delta t}$ 与 \mathbf{x}_t 足够接近时， $p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t)$ 才会明显不等于0，反过来也只有这种情况下 $p(\mathbf{x}_t|\mathbf{x}_{t+\Delta t})$ 才会明显不等于0。因此，我们只需要对 $\mathbf{x}_{t+\Delta t}$ 与 \mathbf{x}_t 足够接近时的情形做近似分析，为此，我们可以用泰勒展开：

$$\log p(\mathbf{x}_{t+\Delta t}) \approx \log p(\mathbf{x}_t) + (\mathbf{x}_{t+\Delta t} - \mathbf{x}_t) \cdot \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t) + \Delta t \frac{\partial}{\partial t} \log p(\mathbf{x}_t) \quad (5)$$

注意不要忽略了 $\frac{\partial}{\partial t}$ 项，因为 $p(\mathbf{x}_t)$ 实际上是“ t 时刻随机变量等于 \mathbf{x}_t 的概率密度”，而 $p(\mathbf{x}_{t+\Delta t})$ 实际上是“ $t + \Delta t$ 时刻随机变量等于 $\mathbf{x}_{t+\Delta t}$ 的概率密度”，也就是说 $p(\mathbf{x}_t)$ 实际上同时是 t 和 \mathbf{x}_t 的函数，所以要多一项 t 的偏导数。代入到式(4)后，配方得到

$$p(\mathbf{x}_t|\mathbf{x}_{t+\Delta t}) \propto \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - [\mathbf{f}_t(\mathbf{x}_t) - g_t^2 \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)] \Delta t\|^2}{2g_t^2\Delta t} + \mathcal{O}(\Delta t)\right)$$

当 $\Delta t \rightarrow 0$ 时， $\mathcal{O}(\Delta t) \rightarrow 0$ 不起作用，因此

$$p(\mathbf{x}_t|\mathbf{x}_{t+\Delta t}) \propto \exp\left(-\frac{\|\mathbf{x}_{t+\Delta t} - \mathbf{x}_t - [\mathbf{f}_t(\mathbf{x}_t) - g_t^2 \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)] \Delta t\|^2}{2g_t^2\Delta t}\right) \\ \approx \exp\left(-\frac{\|\mathbf{x}_t - \mathbf{x}_{t+\Delta t} + [\mathbf{f}_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - g_{t+\Delta t}^2 \nabla_{\mathbf{x}_{t+\Delta t}} \log p(\mathbf{x}_{t+\Delta t})] \Delta t\|^2}{2g_{t+\Delta t}^2\Delta t}\right)$$

即 $p(\mathbf{x}_t|\mathbf{x}_{t+\Delta t})$ 近似一个均值为

$\mathbf{x}_{t+\Delta t} - [\mathbf{f}_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - g_{t+\Delta t}^2 \nabla_{\mathbf{x}_{t+\Delta t}} \log p(\mathbf{x}_{t+\Delta t})] \Delta t$ 、协方差为 $g_{t+\Delta t}^2 \Delta t \mathbf{I}$ 的正态分布，取 $\Delta t \rightarrow 0$ 的极限，那么对应于SDE：

$$d\mathbf{x} = [\mathbf{f}_t(\mathbf{x}) - g_t^2 \nabla_{\mathbf{x}} \log p_t(\mathbf{x})] dt + g_t d\mathbf{w} \quad (8)$$

这就是反向过程对应的SDE，最早出现在

《Reverse-Time Diffusion Equation Models》中。这里我们特意在 p 处标注了下标 t ，以突出这是 t 时刻的分布。

得分匹配

现在我们已经得到了逆向的SDE为(8)，如果进一步知道 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ ，那么就可以通过离散化格式

$$\mathbf{x}_t - \mathbf{x}_{t+\Delta t} = - \left[\mathbf{f}_{t+\Delta t}(\mathbf{x}_{t+\Delta t}) - g_{t+\Delta t}^2 \nabla_{\mathbf{x}_{t+\Delta t}} \log p(\mathbf{x}_{t+\Delta t}) \right] \Delta t - g_{t+\Delta t} \sqrt{\Delta t} \boldsymbol{\epsilon} \quad ($$

来逐步完成“建楼”的生成过程【其中 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 】，从而完成一个生成扩散模型的构建。

那么如何得到 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 呢？ t 时刻的 $p_t(\mathbf{x})$ 就是前面的 $p(\mathbf{x}_t)$ ，它的含义就是 t 时刻的边缘分布。在实际使用时，我们一般会设计能找到 $p(\mathbf{x}_t|\mathbf{x}_0)$ 解析解的模型，这意味着

$$p(\mathbf{x}_t|\mathbf{x}_0) = \lim_{\Delta t \rightarrow 0} \int \cdots \int p(\mathbf{x}_t|\mathbf{x}_{t-\Delta t}) p(\mathbf{x}_{t-\Delta t}|\mathbf{x}_{t-2\Delta t}) \cdots p(\mathbf{x}_{\Delta t}|\mathbf{x}_0) d\mathbf{x}_{t-\Delta t} d\mathbf{x}_{t-2\Delta t} \cdots d\mathbf{x}_{\Delta t}$$

是可以直接求出的，比如当 $\mathbf{f}_t(\mathbf{x})$ 是关于 \mathbf{x} 的线性函数时， $p(\mathbf{x}_t|\mathbf{x}_0)$ 就可以解析求解。在此前提下，有

$$p(\mathbf{x}_t) = \int p(\mathbf{x}_t|\mathbf{x}_0) \tilde{p}(\mathbf{x}_0) d\mathbf{x}_0 = \mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t|\mathbf{x}_0)] \quad (11)$$

于是

$$\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t) = \frac{\mathbb{E}_{\mathbf{x}_0} [\nabla_{\mathbf{x}_t} p(\mathbf{x}_t|\mathbf{x}_0)]}{\mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t|\mathbf{x}_0)]} = \frac{\mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t|\mathbf{x}_0) \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0)]}{\mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t|\mathbf{x}_0)]} \quad (12)$$

可以看到最后的式子具有“ $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0)$ 的加权平均”的形式，由于假设了 $p(\mathbf{x}_t|\mathbf{x}_0)$ 有解析解，因此上式实际上是能够直接估算的，然而它涉及到对全体训练样本 \mathbf{x}_0 的平均，一来计算量大，二来泛化能力也不够好。因此，我们希望用神经网络学一个函数 $s_{\theta}(\mathbf{x}_t, t)$ ，使得它能够直接计算 $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$ 。

很多读者应该对如下结果并不陌生（或者推导一遍也不困难）：

$$\mathbb{E}[\mathbf{x}] = \underset{\boldsymbol{\mu}}{\operatorname{argmin}} \mathbb{E}_{\mathbf{x}} [\|\boldsymbol{\mu} - \mathbf{x}\|^2] \quad (13)$$

即要让 $\boldsymbol{\mu}$ 等于 \mathbf{x} 的均值，只需要最小化 $\|\boldsymbol{\mu} - \mathbf{x}\|^2$ 的均值。同理，要让 $\mathbf{s}_{\theta}(\mathbf{x}_t, t)$ 等于 $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t | \mathbf{x}_0)$ 的加权平均【即 $\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t)$ 】，则只需要最小化 $\|\mathbf{s}_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t | \mathbf{x}_0)\|^2$ 的加权平均，即

$$\frac{\mathbb{E}_{\mathbf{x}_0} \left[p(\mathbf{x}_t | \mathbf{x}_0) \|\mathbf{s}_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t | \mathbf{x}_0)\|^2 \right]}{\mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t | \mathbf{x}_0)]} \quad (14)$$

分母的 $\mathbb{E}_{\mathbf{x}_0} [p(\mathbf{x}_t | \mathbf{x}_0)]$ 只是起到调节Loss权重的作用，简单起见我们可以直接去掉它，这不会影响最优解的结果。最后我们再对 \mathbf{x}_t 积分（相当于对于每一个 \mathbf{x}_t 都要最小化上述损失），得到最终的损失函数

$$\begin{aligned} & \int \mathbb{E}_{\mathbf{x}_0} \left[p(\mathbf{x}_t | \mathbf{x}_0) \|\mathbf{s}_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t | \mathbf{x}_0)\|^2 \right] d\mathbf{x}_t \\ &= \mathbb{E}_{\mathbf{x}_0, \mathbf{x}_t \sim p(\mathbf{x}_t | \mathbf{x}_0) \tilde{p}(\mathbf{x}_0)} \left[\|\mathbf{s}_{\theta}(\mathbf{x}_t, t) - \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t | \mathbf{x}_0)\|^2 \right] \end{aligned} \quad (15)$$

这就是“（条件）得分匹配”的损失函数，之前我们在《从去噪自编码器到生成模型》推导的去噪自编码器的解析解，也是它的一个特例。得分匹配的最早出处可以追溯到2005年的论文《Estimation of Non-Normalized Statistical Models by Score Matching》，至于条件得分匹配的最早出处，笔者追溯到的是2011年的论文《A Connection Between Score Matching and Denoising Autoencoders》。

不过，虽然该结果跟得分匹配是一样的，但其实在这一节的推导中，我们已经抛开了“得分”的概念了，纯粹是由目标自然地引导出来的答案，笔者认为这样的处理过程更有启发性，希望这一推导能降低大家对得分匹配的理解难度。

结果倒推

至此，我们构建了生成扩散模型的一般流程：

- 1、通过随机微分方程(1)定义“拆楼”（前向过程）；
- 2、求 $p(\mathbf{x}_t|\mathbf{x}_0)$ 的表达式；
- 3、通过损失函数(15)训练 $\mathbf{s}_\theta(\mathbf{x}_t, t)$ （得分匹配）；
- 4、用 $\mathbf{s}_\theta(\mathbf{x}_t, t)$ 替换式(8)的 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ ，完成“建楼”（反向过程）。

可能大家看到SDE、微分方程等字眼，天然就觉得“恐慌”，但本质上来说，SDE只是个“幌子”，实际上将对SDE的理解转换到式(2)和式(3)上后，完全就可以抛开SDE的概念了，因此概念上其实是没有太大难度的。

不难发现，定义一个随机微分方程(1)是很容易的，但是从(1)求解 $p(\mathbf{x}_t|\mathbf{x}_0)$ 却是不容易的。原论文的剩余篇幅，主要是对两个有实用性的例子推导和实验。然而，既然求解 $p(\mathbf{x}_t|\mathbf{x}_0)$ 不容易，那么按照笔者的看法，与其先定义(1)再求解 $p(\mathbf{x}_t|\mathbf{x}_0)$ ，倒不如像DDIM一样，先定义 $p(\mathbf{x}_t|\mathbf{x}_0)$ ，然后再来反推对应的SDE？

例如，我们先定义

$$p(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \bar{\alpha}_t \mathbf{x}_0, \bar{\beta}_t^2 \mathbf{I}) \quad (16)$$

并且不失一般性假设起点是 $t = 0$ ，终点是 $t = 1$ ，那么 $\bar{\alpha}_t, \bar{\beta}_t$ 要满足的边界就是

$$\bar{\alpha}_0 = 1, \quad \bar{\alpha}_1 = 0, \quad \bar{\beta}_0 = 0, \quad \bar{\beta}_1 = 1 \quad (17)$$

当然，上述边界条件理论上足够近似就行，也不一定非要精确相等，比如上一篇文章我们分析过DDPM相当于选择了 $\bar{\alpha}_t = e^{-5t^2}$ ，当 $t = 1$ 时结果为 $e^{-5} \approx 0$ 。

有了 $p(\mathbf{x}_t|\mathbf{x}_0)$ ，我们去反推(1)，本质上就是要求解 $p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t)$ ，它要满足

$$p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_0) = \int p(\mathbf{x}_{t+\Delta t}|\mathbf{x}_t)p(\mathbf{x}_t|\mathbf{x}_0)d\mathbf{x}_t \quad (18)$$

我们考虑线性的解，即

$$d\mathbf{x} = f_t \mathbf{x} dt + g_t d\mathbf{w} \quad (19)$$

跟《生成扩散模型漫谈（四）：DDIM = 高观点DDPM》一样，我们写出

记号	含义	采样
$p(\mathbf{x}_{t+\Delta t} \mathbf{x}_0)$	$\mathcal{N}(\mathbf{x}_t; \bar{\alpha}_{t+\Delta t}\mathbf{x}_0, \bar{\beta}_{t+\Delta t}^2 \mathbf{I})$	$\mathbf{x}_{t+\Delta t} = \bar{\alpha}_{t+\Delta t}\mathbf{x}_0 + \bar{\beta}_{t+\Delta t}\boldsymbol{\epsilon}$
$p(\mathbf{x}_t \mathbf{x}_0)$	$\mathcal{N}(\mathbf{x}_t; \bar{\alpha}_t\mathbf{x}_0, \bar{\beta}_t^2 \mathbf{I})$	$\mathbf{x}_t = \bar{\alpha}_t\mathbf{x}_0 + \bar{\beta}_t\boldsymbol{\epsilon}_1$
$p(\mathbf{x}_{t+\Delta t} \mathbf{x}_t)$	$\mathcal{N}(\mathbf{x}_{t+\Delta t}; (1 + f_t\Delta t)\mathbf{x}_t, g_t^2\Delta t \mathbf{I})$	$\mathbf{x}_{t+\Delta t} = (1 + f_t\Delta t)\mathbf{x}_t + g_t\sqrt{\Delta t}\boldsymbol{\epsilon}_2$
$\int p(\mathbf{x}_{t+\Delta t} \mathbf{x}_t) p(\mathbf{x}_t \mathbf{x}_0) d\mathbf{x}_t$		$\mathbf{x}_{t+\Delta t}$ $= (1 + f_t\Delta t)\mathbf{x}_t + g_t\sqrt{\Delta t}\boldsymbol{\epsilon}_2$ $= (1 + f_t\Delta t)(\bar{\alpha}_t\mathbf{x}_0 + \bar{\beta}_t\boldsymbol{\epsilon}_1) + g_t\sqrt{\Delta t}\boldsymbol{\epsilon}_2$ $= (1 + f_t\Delta t)\bar{\alpha}_t\mathbf{x}_0 + ((1 + f_t\Delta t)\bar{\beta}_t\boldsymbol{\epsilon}_1 +$

由此可得

$$\begin{aligned} \bar{\alpha}_{t+\Delta t} &= (1 + f_t\Delta t)\bar{\alpha}_t \\ \bar{\beta}_{t+\Delta t}^2 &= (1 + f_t\Delta t)^2\bar{\beta}_t^2 + g_t^2\Delta t \end{aligned} \quad (20)$$

令 $\Delta t \rightarrow 0$ ，分别解得

$$f_t = \frac{d}{dt}(\ln \bar{\alpha}_t) = \frac{1}{\bar{\alpha}_t} \frac{d\bar{\alpha}_t}{dt}, \quad g_t^2 = \bar{\alpha}_t^2 \frac{d}{dt} \left(\frac{\bar{\beta}_t^2}{\bar{\alpha}_t^2} \right) = 2\bar{\alpha}_t\bar{\beta}_t \frac{d}{dt} \left(\frac{\bar{\beta}_t}{\bar{\alpha}_t} \right) \quad (21)$$

取 $\bar{\alpha}_t \equiv 1$ 时，结果就是论文中的VE-SDE（Variance Exploding SDE）；而如果取 $\bar{\alpha}_t^2 + \bar{\beta}_t^2 = 1$ 时，结果就是原论文中的VP-SDE（Variance Preserving SDE）。

至于损失函数，此时我们可以算得

$$\nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t|\mathbf{x}_0) = -\frac{\mathbf{x}_t - \bar{\alpha}_t\mathbf{x}_0}{\bar{\beta}_t^2} = -\frac{\boldsymbol{\epsilon}}{\bar{\beta}_t} \quad (22)$$

第二个等号是因为 $\mathbf{x}_t = \bar{\alpha}_t\mathbf{x}_0 + \bar{\beta}_t\boldsymbol{\epsilon}$ ，为了跟以往的结果对齐，我们设

$s_{\theta}(\mathbf{x}_t, t) = -\frac{\boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t)}{\bar{\beta}_t}$ ，此时式(15)为

$$\frac{1}{\bar{\beta}_t^2} \mathbb{E}_{\mathbf{x}_0 \sim \tilde{p}(\mathbf{x}_0), \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})} \left[\left\| \boldsymbol{\epsilon}_\theta(\bar{\alpha}_t \mathbf{x}_0 + \bar{\beta}_t \boldsymbol{\varepsilon}, t) - \boldsymbol{\varepsilon} \right\|^2 \right] \quad (23)$$

忽略系数后就是DDPM的损失函数，而用 $-\frac{\boldsymbol{\epsilon}_\theta(\mathbf{x}_{t+\Delta t}, t+\Delta t)}{\bar{\beta}_{t+\Delta t}}$ 替换掉式(9)的

$\nabla_{\mathbf{x}_{t+\Delta t}} \log p(\mathbf{x}_{t+\Delta t})$ 后，结果与DDPM的采样过程具有相同的一阶近似（意味着 $\Delta t \rightarrow 0$ 时两者等价）。

文章小结

本文主要介绍了宋飏博士建立的利用SDE理解扩散模型的一般框架，其中包括以尽可能直观的语言推导了反向SDE、得分匹配等结果，并对方程的求解给出了自己的想法。

转载到请包括本文地址：<https://spaces.ac.cn/archives/9209>

更详细的转载事宜请参考：《科学空间FAQ》

如果您需要引用本文，请参考：

苏剑林. (Aug. 03, 2022). 《生成扩散模型漫谈（五）：一般框架之SDE篇》 [Blog post]. Retrieved from <https://spaces.ac.cn/archives/9209>

```
@online{kexuefm-9209,
  title={生成扩散模型漫谈（五）：一般框架之SDE篇},
  author={苏剑林},
  year={2022},
  month={Aug},
  url={\url{https://spaces.ac.cn/archives/9209}},
}
```