


Mip-NeRF 360: Unbounded Anti-Aliased Neural Radiance Fields

Paper: <https://arxiv.org/pdf/2111.12077v3.pdf>

Year: 2022

Mip Nerf



贡献

1. 解决了Mip-Nerf不能很好用于360度无边界场景渲染的问题;
2. 解决了采样效率低的问题;
3. 解决了密度构建中的结构不准确问题。

360度无边界场景的渲染

目前渲染场景主要分为三种：有边界小场景，前向无边界场景，360度无边界场景。

<https://www.matthewtancik.com/nerf>

<https://jonbarron.info/mipnerf360/>

Nerf对无边界场景的建模通常是要比有边界建模难度高的。



(a) bounding volume for the truck only

(b) bounding volume for the entire scene

前向无边界场景里，可以通过将世界坐标转为NDC坐标来一定程度解决。


image.png

但是在360度场景里面就比较麻烦了。

要想对360度无边界场景进行建模，有两方面是需要关注的：


- 1. 采样策略；
- 2. 输入策略；

非均匀采样



在场景下，有粗采样与细采样，粗采样一般使用等距采样，但是根据前面的分析，这种等距采样，在大场景下是有问题的，比较合理的一种采样方式是，近处的采样点多一些，远处的采样点少一些，因此近处的细节比较多。

输入




本文方法

差异采样技术


1. 先在0-1之间均匀采样一些点;
2. 设采样到的点是 s , $s \in [0, 1]$, 则新的采样点是:

$$s' = \frac{1}{s \frac{1}{f} + (1 - s) \frac{1}{n}}$$



这就是论文中给出的这个公式:

$$s \triangleq \frac{g(t) - g(t_n)}{g(t_f) - g(t_n)}, \quad t \triangleq g^{-1}(s \cdot g(t_f) + (1 - s) \cdot g(t_n)), \quad (11)$$



$$\text{contract}(\mathbf{x}) = \begin{cases} \mathbf{x} & \|\mathbf{x}\| \leq 1 \\ \left(2 - \frac{1}{\|\mathbf{x}\|}\right) \left(\frac{\mathbf{x}}{\|\mathbf{x}\|}\right) & \|\mathbf{x}\| > 1 \end{cases} \quad (10)$$

这样一个好处是，重参数化以后，坐标值的变化不会很大。

想要使用重参数化技术，还有一个问题要解决，就是重参数化以后怎么求一个截椎体里面的均值与协方差。也就是说原数据映射到 $f(\mathbf{x})$ 上之后，原来的均值 u 与协方差矩阵 Σ 会变为多少？

这种非线性变化下，进行求解，是比较困难的，但是线性下求解相对容易：

$$\begin{aligned} y &= Ax + b \\ E(y) &= E(Ax + b) = E(Ax) + E(b) = AE(x) + b = Au + b \\ D(y) &= D(Ax + b) = AD(x)A^T \end{aligned}$$

所以，这里将 $f(\mathbf{x})$ 在 u 点进行一阶泰勒展开，将一个非线性的函数进行了线性化处理。

$$f(\mathbf{x}) = f(u) + J_f(u)(\mathbf{x} - u)$$

线性化以后：


$$\begin{aligned} E(f(\mathbf{x})) &= E(f(u) + J_f(u)(\mathbf{x} - u)) \\ &= f(u) + E(J_f(u)(\mathbf{x} - u)) \\ &= f(u) + J_f(u)E(\mathbf{x} - u) \\ &= f(u) \end{aligned}$$

$$\begin{aligned} D(f(\mathbf{x})) &= D(f(u) + J_f(u)(\mathbf{x} - u)) \\ &= D(J_f(u)(\mathbf{x} - u)) \\ &= D(J_f(u)\mathbf{x}) \\ &= J_f(u)D(\mathbf{x})J_f(u)^T \end{aligned}$$

$$f(\mathbf{x}) \approx f(\boldsymbol{\mu}) + \mathbf{J}_f(\boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu}) \quad (8)$$


$$f(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = (f(\boldsymbol{\mu}), \mathbf{J}_f(\boldsymbol{\mu})\boldsymbol{\Sigma}\mathbf{J}_f(\boldsymbol{\mu})^T)$$

总体过程：




采样效率低

mip-NeRF



Our Model



proposal MLP: 新加的，输入xyz坐标，得到weight的值。

NeRF MLP: 跟原来一样，输入xyz坐标与view dir, 得到密度,weight与颜色值。


其中，图中的 $\mathcal{L}_{\text{prop}}$ 是用来约束，coarse阶段出来的weight和fine阶段出来的weight分布要差不多。

$\mathcal{L}_{\text{prop}}$ 的计算

要使proposal MLP和NeRF MLP输出的weight分布是一致的，一个直观的想法是，可以计算两个直方图的损失，但是由于coarse和fine阶段采样的点不一样，所以不太方便直接使用MSE或者L1损失。

以下这个图为例，表示的都是同一weight分布，但是由于两个采样点的位置不同，其直方图看起来非常不一样。

本文用的方法如下：




书上的公式如下：


$$\text{bound}(\hat{\mathbf{t}}, \hat{\mathbf{w}}, T) = \sum_{j: T \cap \hat{T}_j \neq \emptyset} \hat{w}_j. \quad (12)$$

$$\mathcal{L}_{\text{prop}}(\mathbf{t}, \mathbf{w}, \hat{\mathbf{t}}, \hat{\mathbf{w}}) = \sum_i \frac{1}{w_i} \max(0, w_i - \text{bound}(\hat{\mathbf{t}}, \hat{\mathbf{w}}, T_i))^2, \quad (13)$$


密度结构不准确



(a) no $\mathcal{L}_{\text{dist}}$



(b) no $\mathcal{L}_{\text{dist}}$, w/noise [33]



(c) with $\mathcal{L}_{\text{dist}}$


大场景对密度的预测不是太准确，会有一些半透明的物体漂浮在空中，一个准确的密度的预测其weight分布应该是这样的：

mip nerf 360里面使用了一个损失函数对其进行了约束：

$$\mathcal{L}_{\text{dist}}(\mathbf{s}, \mathbf{w}) = \iint_{-\infty}^{\infty} \mathbf{w}_{\mathbf{s}}(u) \mathbf{w}_{\mathbf{s}}(v) |u - v| d_u d_v, \quad (14)$$


离散形式：

当两个点在不同的采样段上：



$$L_{dist}(S, W) = \sum_{i,j} w_i w_j \left| \frac{s_i + s_{i+1}}{2} - \frac{s_j + s_{j+1}}{2} \right|$$

当两个点在同一采样段上：



$$\begin{aligned} L_{dist}(s_i, w_i) &= \int_{s_i}^{s_{i+1}} \int_{s_i}^{s_{i+1}} w_i w_i |u - v| du dv \\ &= w_i^2 \int_{s_i}^{s_{i+1}} \int_{s_i}^{s_{i+1}} |u - v| du dv \\ &= w_i^2 \frac{1}{3} (s_{i+1} - s_i) \end{aligned}$$

将每一段的都加起来：

$$L_{dist}(S, W) = \frac{1}{3} \sum_i w_i^2 (s_{i+1} - s_i)$$

书里给的公式：

$$\begin{aligned} \mathcal{L}_{dist}(\mathbf{s}, \mathbf{w}) &= \sum_{i,j} w_i w_j \left| \frac{s_i + s_{i+1}}{2} - \frac{s_j + s_{j+1}}{2} \right| \\ &\quad + \frac{1}{3} \sum_i w_i^2 (s_{i+1} - s_i) \end{aligned} \quad (15)$$

